CPU Scheduling

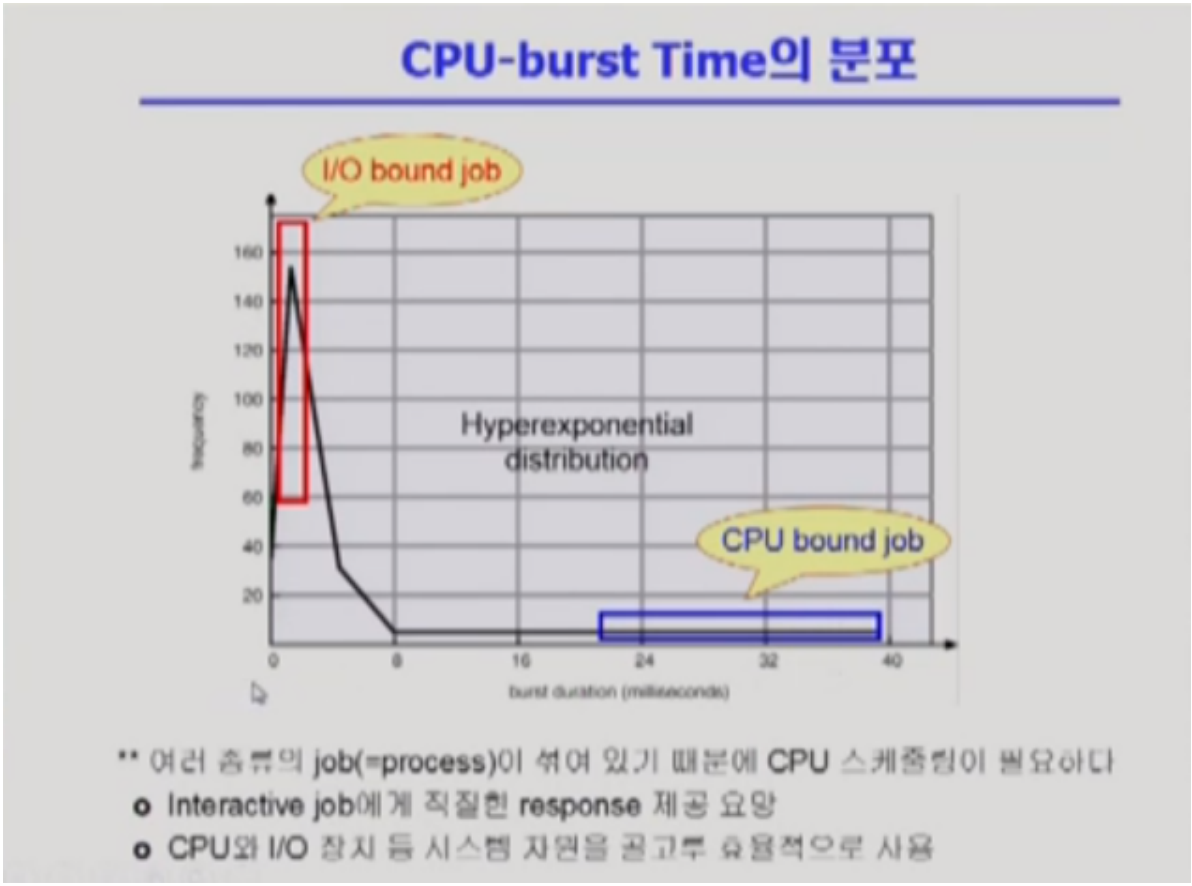

- cpu burst가 짧다 ? -> I/O가 중간에 많이 끼어들어서 짧게 나타난다.
- cpu burst가 길다 ? -> I/O가 거의 끼어들지 않아서 길게 나타남.

- I/O bound job : cpu burst가 짧은 프로그램들은 보통 사람과 하기 때문에 cpu를 너무 늦게 주면 응답시간이 길어져서 답답함
- cpu 스케쥴링은 현재 ready queue에 들어와있는 즉 cpu를 얻고자 하는 프로세스들 중에서 어떤 프로세스한테 cpu를 줄건지 정하는 메커니즘

스케쥴링 알고리즘 2분류

- non - preemtive(비선점형 스케쥴링) : 강제로 cpu를 빼앗지 않음
- preemtive(선점형 스케쥴링) : 강제로 빼앗음

스케쥴링 알고리즘 평가 방법

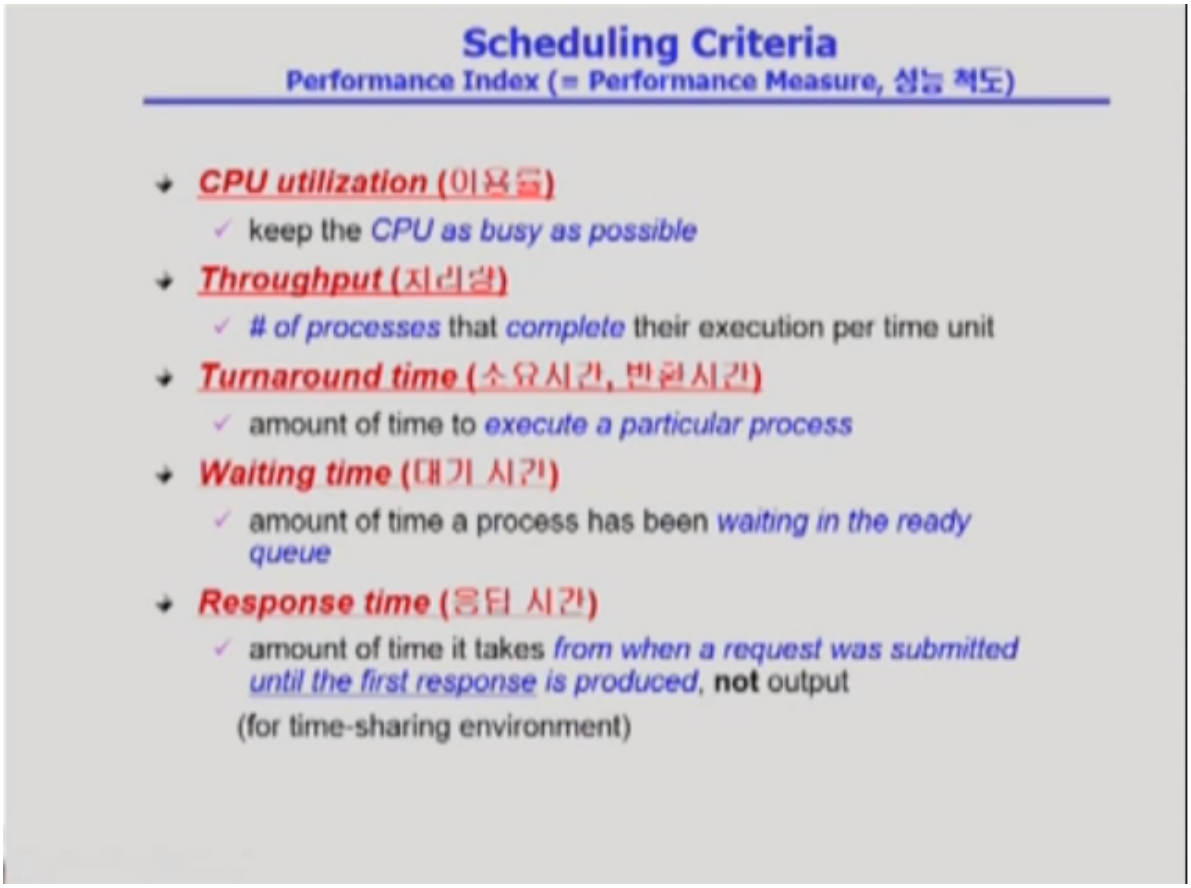

시스템 상에서 성능 척도

- CPU utilization
  - 전체 시간중에서 cpu가 놀지 않고 일한 시간
  - cpu를 가능한 일 많이 시켜라 -> 시스템 상에서 이득
- Throughput
  - 주어진 시간 동안 몇개의 일을 처리했는지

프로세스 입장에서 성능 척도

- Turnaround time
  - cpu를 쓰러 들어와서 다 쓰고 나갈때까지 걸린 시간
- Watiting time
  - 대기 시간
- Response time
  - ready queue에 들어와서 처음으로 cpu를 얻기까지 걸린 시간

CPU 스케쥴링 알고리즘 종류

Scheduling Algorithms

- *FCFS (First-Come First-Served)*
- *SJF (Shortest-Job-First)*
- *SRTF (Shortest-Remaining-Time-First)*
- *Priority Scheduling*
- *RR (Round Robin)*
- *Multilevel Queue*
- *Multilevel Feedback Queue*

FCFS

- 먼저 온 순서대로 처리
- 비선점형
- 별로 효율적이지 않음

FCFS (First-Come First-Served)

- Example:

Process	Burst Time
P_1	24
P_2	3
P_3	3

- 프로세스의 도착 순서 P_1, P_2, P_3
  스케줄 순서를 Gantt Chart로 나타내면 다음과 같다

- Waiting time for P_1 = 0; P_2 = 24; P_3 = 27
- Average waiting time: (0 + 24 + 27)/3 = 17

SJF

- CPU를 사용하고자 하는 시간이 가장 짧은 프로그램에서 CPU를 줌
- 평균 대기 시간을 가장 줄여줌
- 두가지 방식을 나누어서 생각 가능
  - 비선점형
    - 일단 기다리는 프로세스 중에서 가장 짧은애한테 cpu주면 더 짧은 프로세스가 도착하더라도 앞에 애가 끝날때까지는 못 넘겨준다
  - 선점형
    - cpu를 줬다 하더라도 더 짧은 애가 도착하면 그 프로세스한테 cpu를 준다
    - SRTF라고도 부름
    - 평균 대기 시간 더 짧음

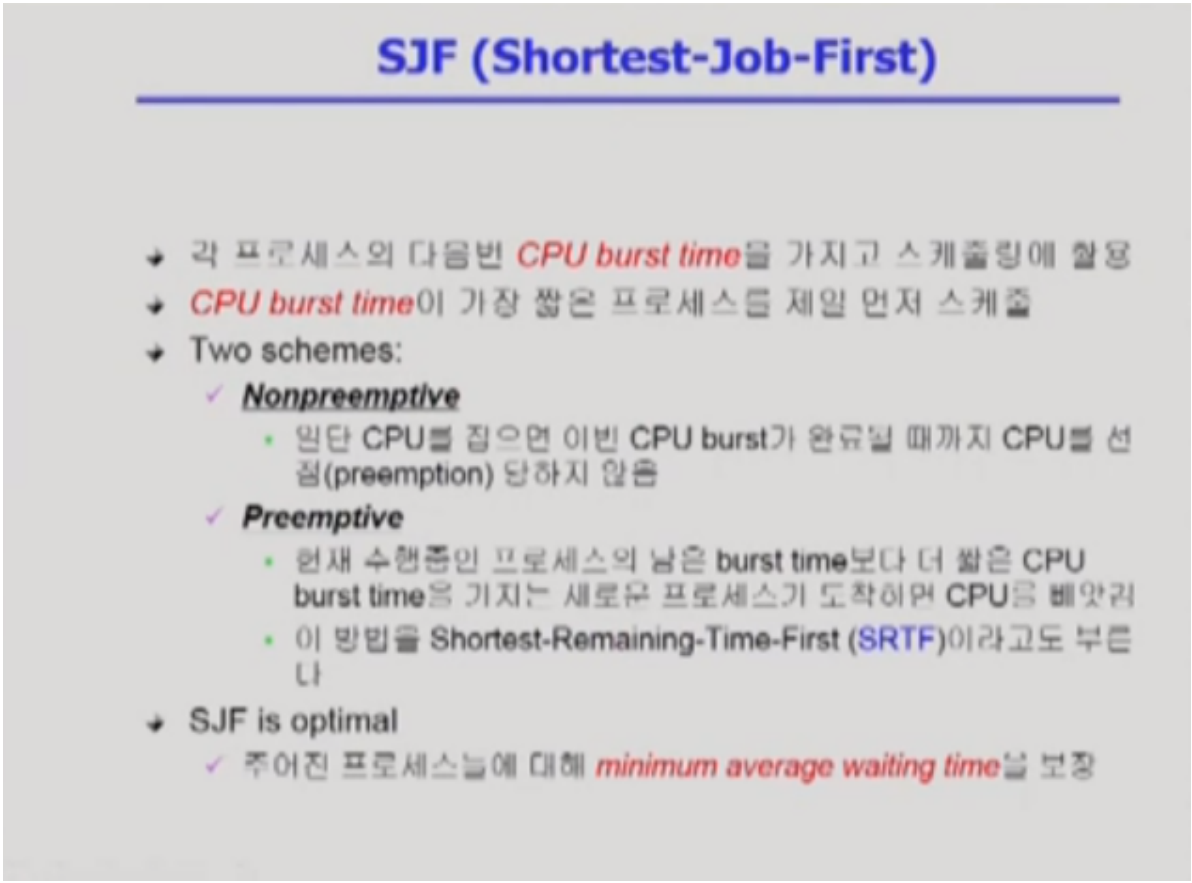

- 예시

- 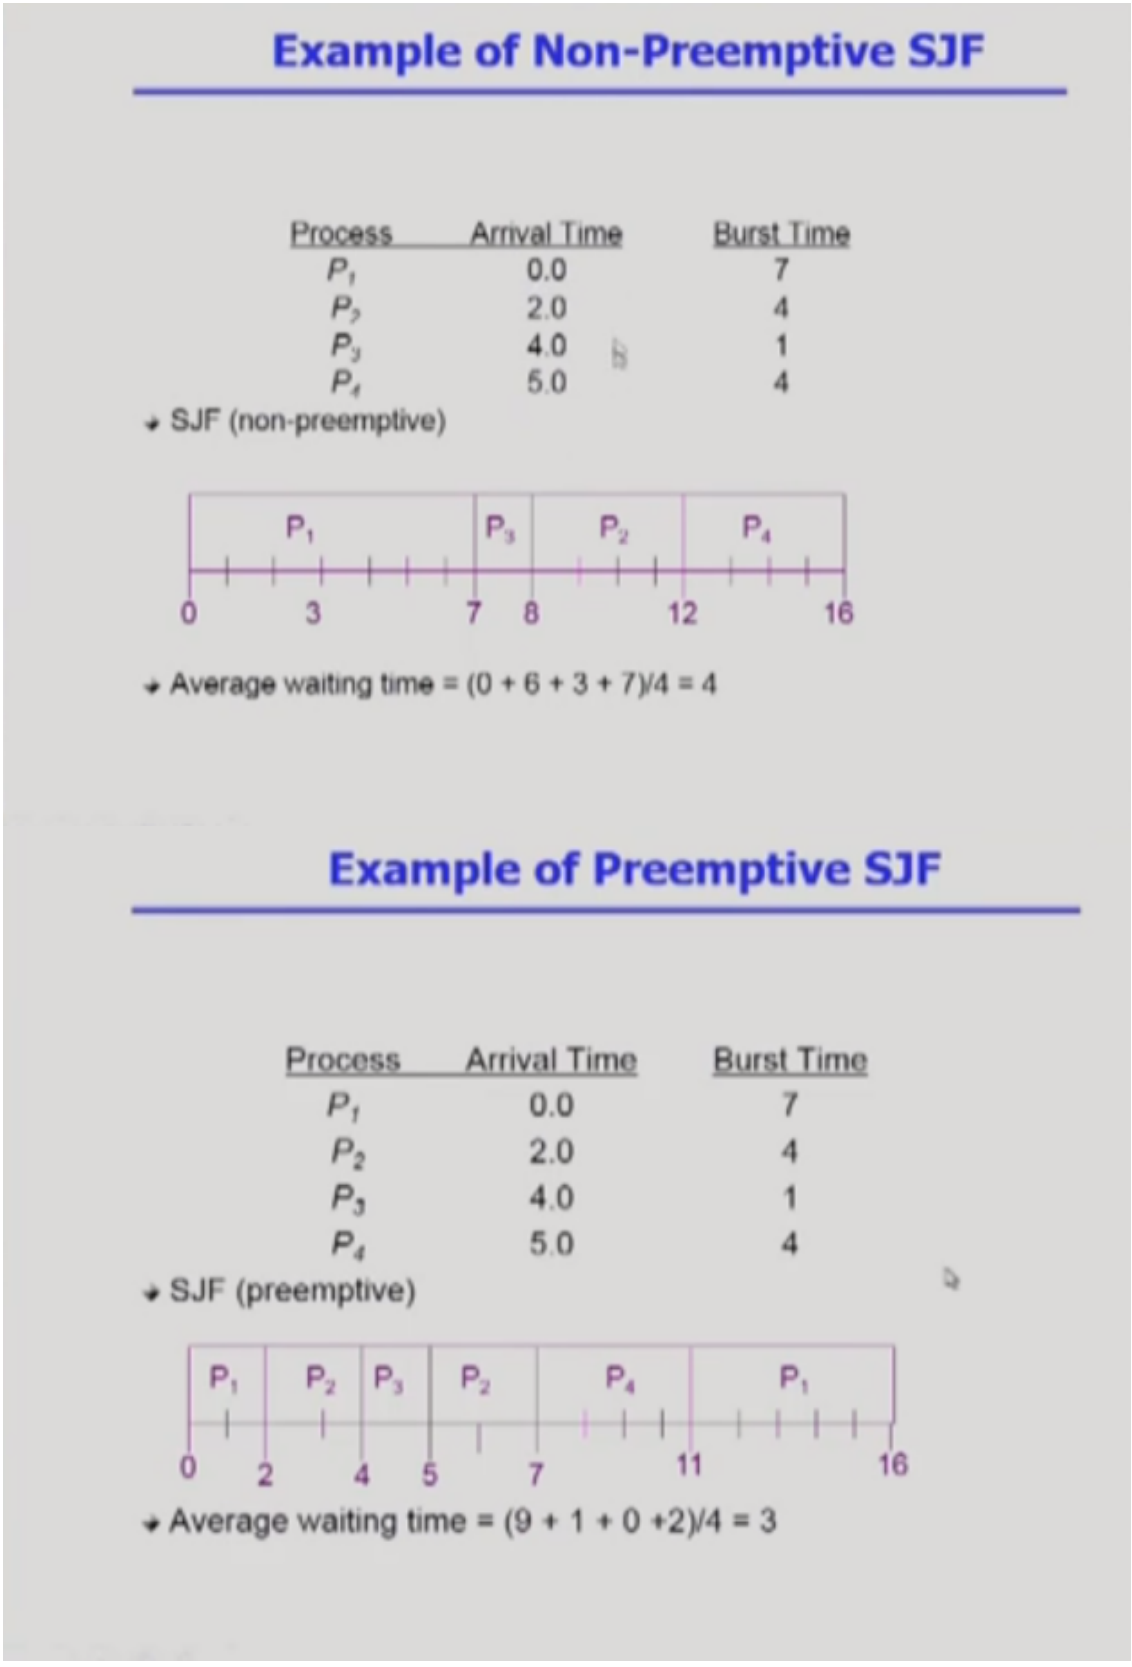

-

- 두가지 문제점 존재
  - Starvation : 극단적으로 cpu 사용시간이 짧은거를 선호 함 그래서 cpu 사용시간이 긴 프로세스들은 사용 못 할 수 있음
  - cpu 사용시간을 미리 알 수 없다. 대신 추정은 가능

다음 CPU Burst Time의 예측

- 다음번 *CPU burst time*을 어떻게 알 수 있는가?
  (input data, branch, user ...)
- 추정(*estimate*)만이 가능하다
- 과거의 CPU burst time을 이용해서 추정
  (exponential averaging)

1. t_n = actual lenght of n^{th} CPU burst
2. τ_{n+1} – predicted value for the next CPU burst
3. $\alpha, 0 \le \alpha \le 1$
4. Define : $\tau_{n+1} = \alpha t_n + (1-\alpha)\tau_n$

- 과거의 CPU burst time을 이용해서 추정
- t : 실제 cpu 사용 시간
- τ : cpu 사용을 예측한 시간

Exponential Averaging

- $\alpha = 0$
  - ✓ $\tau_{n+1} = \tau_n$
  - ✓ Recent history does not count.
- $\alpha = 1$
  - ✓ $\tau_{n+1} = t_n$
  - ✓ Only the actual last CPU burst counts.
- 식을 풀면 다음과 같다

$$\tau_{n+1} = \alpha t_n + (1-\alpha)\alpha t_{n-1} + \cdots + (1-\alpha)^j \alpha t_{n-j} + \cdots + (1-\alpha)^{n+1} \tau_0$$

- α와 $(1-\alpha)$가 둘다 1 이하이므로 후속 term은 선행 term보다 적은 가중치 값을 가진다

Priority Scheduling

- 우선순위가 높은 프로세스에게 cpu를 줌
- 우선순위가 주어짐(작은 수 --> 더 우선 순위)
- 두가지 방법 가능
  - 비선점형
  - 선점형
- 문제점은 똑같이 starvation(기아현상)이 있다
  - 해결하기 위해 Aging 기법을 사용
  - 아무리 우선순위가 높아도 시간이 지남에따라 우선순위를 줄여줌

Round Robin(RR)

- 현대적인 CPU스케쥴링은 Round Robin에 기반함
- 선점형
- 동일한 할당 시간을 세팅해서 주고 시간이 지나면 cpu 뺏어감
- 장점
  - 응답시간이 빨라짐
- 할당시간을 아주 크게 잡으면 FCFS와 같아진다
- 할당시간을 아주 작게 잡으면 context switch 가 너무 자주 발생하여 오버헤드가 커진다.
- 고로 할당시간을 10 ~100 사이로 적당하게 잡는것이 중요하다
- 예시
-